

Crhisângela G. R. Ferreira

**Geração combinatória de moléculas via  
recombinação de fragmentos representados em  
SMILES**

Santo André, SP

2026

Crhisângela G. R. Ferreira

## **Geração combinatória de moléculas via recombinação de fragmentos representados em SMILES**

Exame de qualificação apresentado ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal do ABC como parte dos requisitos para obtenção do título de Mestre em Ciência da Computação.

Universidade Federal do ABC – UFABC  
Programa de Pós-Graduação em Ciência da Computação

Orientador Prof. Dr. Jesús P. Mena-Chalco  
Coorientador Prof. Dr. Mauricio Coutinho

Santo André, SP  
2026

# PORTUGUÊS

**Palavras-chave:** palavra 1. palavra 2. palavra 3.

# ENGLISH

**Keywords:** keyword 1. keyword 2. keyword 3.

## LISTA DE ILUSTRAÇÕES

## LISTA DE TABELAS

|          |   |                                                                                                 |    |
|----------|---|-------------------------------------------------------------------------------------------------|----|
| Tabela 1 | – | Comparação entre abordagens de geração molecular discutidas. . . . .                            | 13 |
| Tabela 2 | – | Braços do experimento (todos com mesmo $N$ , mesmos anéis-semente e<br>mesmo pipeline). . . . . | 19 |
| Tabela 3 | – | Cronograma de atividades previstas. . . . .                                                     | 22 |

## LISTA DE ABREVIATURAS E SIGLAS

|        |                                                             |
|--------|-------------------------------------------------------------|
| ABNT   | Associação Brasileira de Normas Técnicas                    |
| PPG    | Programa de Pós-Graduação                                   |
| SMILES | Simplified Molecular Input Line Entry System                |
| QSAR   | Quantitative Structure-Activity Relationship                |
| UFABC  | Universidade Federal do ABC                                 |
| ZSA    | Algoritmo de Zhang-Shasha ( <i>Zhang-Shasha Algorithm</i> ) |

# SUMÁRIO

|            |                                                        |           |
|------------|--------------------------------------------------------|-----------|
| <b>1</b>   | <b>INTRODUÇÃO</b>                                      | <b>9</b>  |
| <b>1.1</b> | <b>Contextualização e motivação</b>                    | <b>9</b>  |
| <b>1.2</b> | <b>Definição do problema</b>                           | <b>10</b> |
| <b>2</b>   | <b>REVISÃO DE LITERATURA</b>                           | <b>11</b> |
| <b>2.1</b> | <b>Fundamentos</b>                                     | <b>11</b> |
| 2.1.1      | Espectroscopia UV-Vis                                  | 11        |
| 2.1.2      | Relação entre estrutura molecular e absorção UV-Vis    | 11        |
| 2.1.3      | Representações computacionais de moléculas             | 12        |
| 2.1.4      | Tree Edit Distance                                     | 12        |
| <b>2.2</b> | <b>Estado da arte em geração molecular</b>             | <b>12</b> |
| <b>2.3</b> | <b>Síntese e lacunas</b>                               | <b>13</b> |
| <b>3</b>   | <b>JUSTIFICATIVA DA ESCOLHA METODOLÓGICA</b>           | <b>14</b> |
| <b>3.1</b> | <b>Por que recombinação de fragmentos e árvores</b>    | <b>14</b> |
| <b>3.2</b> | <b>Por que a TED e não outras medidas de distância</b> | <b>15</b> |
| <b>3.3</b> | <b>Limitações reconhecidas</b>                         | <b>16</b> |
| <b>4</b>   | <b>OBJETIVOS</b>                                       | <b>16</b> |
| <b>4.1</b> | <b>Objetivo geral</b>                                  | <b>16</b> |
| <b>4.2</b> | <b>Objetivos específicos</b>                           | <b>16</b> |
| <b>4.3</b> | <b>Relevância da pesquisa</b>                          | <b>16</b> |
| <b>5</b>   | <b>METODOLOGIA PROPOSTA</b>                            | <b>18</b> |
| <b>5.1</b> | <b>Visão geral do pipeline</b>                         | <b>18</b> |
| <b>5.2</b> | <b>Geração de fragmentos e combinação</b>              | <b>18</b> |
| <b>5.3</b> | <b>Representação estrutural (árvore/gráfo)</b>         | <b>18</b> |
| <b>5.4</b> | <b>Avaliação de diversidade estrutural</b>             | <b>18</b> |
| <b>5.5</b> | <b>Ambiente e ferramentas</b>                          | <b>18</b> |
| <b>5.6</b> | <b>Delineamento experimental</b>                       | <b>18</b> |
| 5.6.1      | Regra de seleção de parceiros                          | 18        |
| 5.6.2      | Observação preliminar sobre a TED nas árvores atuais   | 18        |
| 5.6.3      | Braços do experimento                                  | 18        |
| 5.6.4      | Métricas de avaliação                                  | 19        |
| 5.6.5      | Plano estatístico                                      | 19        |
| 5.6.6      | Critérios de avaliação                                 | 20        |
| <b>5.7</b> | <b>Validação espectroscópica</b>                       | <b>20</b> |
| <b>6</b>   | <b>RESULTADOS PRELIMINARES</b>                         | <b>21</b> |
| <b>6.1</b> | <b>Infraestrutura de geração implementada</b>          | <b>21</b> |
| <b>6.2</b> | <b>Diversidade estrutural observada</b>                | <b>21</b> |
| <b>6.3</b> | <b>Limitações observadas e próximos passos</b>         | <b>21</b> |
| <b>7</b>   | <b>CRONOGRAMA</b>                                      | <b>22</b> |

**REFERÊNCIAS . . . . . 23**

# 1 INTRODUÇÃO

## 1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

Moléculas que absorvem radiação ultravioleta (UV) e visível (Vis) são importantes em diversos setores: no monitoramento de contaminantes e de processos de fotodegradação em água e na quantificação de fármacos (ROCHA et al., 2018), e em células solares orgânicas e OLEDs (OSTROVERKHOVA, 2016). A capacidade de uma molécula de absorver radiação em determinadas regiões do espectro está relacionada à sua estrutura molecular e às características eletrônicas dela decorrentes (ATKINS; PAULA, 2018; SILVERSTEIN; WEBSTER; KIEMLE, 2005). Identificar e desenvolver moléculas com propriedades ópticas específicas é, portanto, um problema de interesse em Química e em Ciência de Materiais.

Encontrar novos compostos com propriedades de interesse é difícil devido à extensão do espaço químico: Polishchuk, Madzhidov e Varnek (2013) estimaram em cerca de  $10^{33}$  as estruturas compatíveis com moléculas *drug-like*, e Bohacek, McMartin e Guida (1996) em ordem de  $10^{60}$  as moléculas orgânicas pequenas, valores que dependem do critério de contagem adotado. Esses números descrevem o espaço químico geral, e não o espaço de busca deste trabalho, que é restrito a um catálogo finito de fragmentos (Seção 1.2). Eles motivam, porém, estratégias computacionais que restrinjam a busca a regiões associadas a propriedades específicas (TKATCHENKO, 2020). Na própria espectroscopia UV-Vis, métodos de aprendizado de máquina já são usados para prever características de espectros a partir da estrutura (MAMEDE; PEREIRA; SOUSA, 2021).

Diferentes abordagens têm sido empregadas na geração e na otimização de moléculas, entre elas autoencoders variacionais (GÓMEZ-BOMBARELLI et al., 2018; JIN; BARZILAY; JAAKKOLA, 2018), redes adversárias generativas (GUIMARAES et al., 2017; CAO; KIPF, 2018), aprendizado por reforço (OLIVECRONA et al., 2017; YOU et al., 2018) e arquiteturas híbridas que combinam algoritmos genéticos, redes recorrentes e modelos substitutos de cálculos quânticos (KWON et al., 2021). Os métodos baseados em redes neurais costumam depender de bases de dados para treinamento e de modelos de propriedades, e a origem estrutural de cada molécula gerada nem sempre é explícita. Além disso, o resultado depende da representação molecular adotada (*strings*, *fingerprints* ou grafos), pois ela determina quais modificações estruturais são possíveis, se a validade química é preservada e como a similaridade entre moléculas é medida.

Representações lineares, como o SMILES, descrevem estruturas de forma compacta e são amplamente usadas em modelos generativos (WEININGER, 1988; GÓMEZ-BOMBARELLI et al., 2018), mas a representação sequencial não explicita as relações hierárquicas entre subestruturas, e moléculas relacionadas podem ter representações distintas (JIN; BARZILAY; JAAKKOLA, 2018). Como alternativa, trabalhos recentes adotam representações hierárquicas baseadas em subestruturas. O *Junction Tree Variational Autoencoder* (JT-VAE) usa uma árvore de subestruturas para gerar moléculas válidas (JIN; BARZILAY; JAAKKOLA, 2018), e abordagens posteriores combinaram árvores com aprendizado por reforço e com decomposição e recombinação molecular (ISHITANI; KATAOKA; RIKIMARU, 2022; YAMADA; SUGIYAMA, 2023).

Em paralelo, métodos sem treinamento exploram o espaço por recombinação direta de estruturas, como os algoritmos genéticos sobre grafos moleculares com *crossover* de

fragmentos (JENSEN, 2019), e há representações que garantem validade por construção, como o SELFIES (KRENN et al., 2020). Até onde se pôde verificar nesta revisão, porém, nesses métodos a escolha dos pares a recombinar não é feita por uma medida explícita de distância entre as organizações hierárquicas das moléculas, que permitiria controlar o quão distantes entre si são as estruturas combinadas.

A *Tree Edit Distance* (TED) quantifica a diferença entre duas árvores pelo custo mínimo de operações de edição sobre nós. Sua versão para árvores ordenadas tem algoritmo polinomial (ZHANG; SHASHA, 1989; BILLE, 2005), enquanto a versão para árvores não ordenadas é NP-difícil (ZHANG; STATMAN; SHASHA, 1992). Como o catálogo é finito, a matriz de distâncias pode ser pré-calculada, e a escolha da TED é, portanto, uma justificativa prática e a ser avaliada empiricamente, e não uma necessidade teórica (Capítulo 3). A TED já foi aplicada a árvores de rotas sintéticas, no agrupamento de rotas (GENHEDEN; ENGKVIST; BJERRUM, 2021), mas não a árvores de fragmentos moleculares. Em outro domínio, Mizrahi et al. (2025) representam receitas culinárias como árvores e usam o algoritmo de Zhang–Shasha para recombiná-las, obtendo saídas mais diversas e mais novas do que a geração direta por modelos de linguagem. Essa evidência motiva o uso da TED neste trabalho, cuja aplicação, como discutido na Seção 2.2, difere da deles.

## 1.2 DEFINIÇÃO DO PROBLEMA

Este trabalho trata da geração combinatória de moléculas candidatas, com potencial para absorção UV-Vis, por recombinação de fragmentos químicos. As moléculas são construídas a partir de um catálogo de fragmentos (anéis, grupos substituintes e pontes conjugadas), na forma *anel – ponte – anel*, com os anéis podendo receber substituintes em posições definidas. Por construção, esse espaço é combinatório e cresce rapidamente com o tamanho do catálogo, de modo que a escolha de quais anéis combinar determina tanto a diversidade do conjunto gerado quanto a eficiência da busca.

Propõe-se representar cada anel e seus substituintes como uma árvore ordenada de forma uniforme (anel  $\rightarrow$  posição  $\rightarrow$  fragmento) e usar a TED, calculada pelo algoritmo de Zhang–Shasha (ZHANG; SHASHA, 1989), como critério estrutural para selecionar o anel parceiro de cada anel-semente. Como a TED mede a distância entre as representações estruturais, e não entre espectros, ela é usada para controlar a diversidade estrutural da recombinação, evitando que a geração repita combinações muito parecidas com as já obtidas. A viabilidade química de cada candidato é garantida por um pipeline de junção com verificação de valência, sanitização e aromatização, com mecanismos de nova tentativa quando uma combinação é inválida. As moléculas geradas são então avaliadas quanto a indicadores associados à absorção UV-Vis, como a extensão do sistema conjugado, que também pode orientar a escolha das pontes e dos parceiros nas gerações seguintes.

Diante disso, o trabalho investiga se a TED sobre uma representação hierárquica pode orientar a recombinação de fragmentos, produzindo candidatos válidos, novos e estruturalmente diversos, com propriedades de interesse para absorção UV-Vis.

## 2 REVISÃO DE LITERATURA

### 2.1 FUNDAMENTOS

#### 2.1.1 Espectroscopia UV-Vis

A espectroscopia é o estudo da interação entre a radiação eletromagnética e a matéria. A espectroscopia de absorção UV-Vis baseia-se na capacidade de certas moléculas absorverem radiação nas regiões ultravioleta e visível, em uma faixa aproximadamente entre 190 e 800 nm, cujos limites variam com o instrumento e a aplicação (ROCHA et al., 2018; ROJAS; OJEDA, 2009).

A absorção ocorre quando a energia da radiação incidente é suficiente para promover uma transição eletrônica entre estados de diferentes energias. Em uma descrição por orbitais moleculares, uma dessas transições pode ser associada à promoção de um elétron do orbital molecular ocupado de maior energia (HOMO) para o orbital desocupado de menor energia (LUMO) (PAVIA et al., 2015; ATKINS; PAULA, 2018). A relação entre a diferença de energia e o comprimento de onda absorvido é

$$E = \frac{hc}{\lambda}, \quad (2.1)$$

em que  $E$  é a energia da radiação,  $h$  a constante de Planck,  $c$  a velocidade da luz e  $\lambda$  o comprimento de onda. Menores diferenças de energia entre os estados eletrônicos correspondem, portanto, a maiores comprimentos de onda de absorção. Os grupos responsáveis pela absorção são denominados cromóforos (PAVIA et al., 2015; SKOOG; HOLLER; CROUCH, 2017).

#### 2.1.2 Relação entre estrutura molecular e absorção UV-Vis

A estrutura molecular influencia a absorção ao modificar a distribuição eletrônica e as energias das transições. Entre as características relevantes estão a extensão da conjugação, a presença de grupos auxocrômicos e a existência de sistemas aromáticos.

Sistemas conjugados são formados por ligações simples e duplas alternadas que deslocalizam os elétrons  $\pi$ ; o aumento da conjugação reduz a diferença de energia entre os estados envolvidos e desloca o máximo de absorção para maiores comprimentos de onda (PAVIA et al., 2015; SKOOG; HOLLER; CROUCH, 2017). Os auxocromos, quando ligados a um cromóforo, podem alterar a intensidade e a posição das bandas, devido aos pares de elétrons livres que interagem com o sistema eletrônico. Anéis aromáticos, em especial os fusionados, podem absorver em maiores comprimentos de onda pela maior deslocalização, embora a geometria (por exemplo, a planaridade) também influencie a sobreposição dos orbitais.

Dessa forma, a conectividade molecular fornece informação relevante, mas não descreve isoladamente o comportamento espectroscópico, que depende também de fatores eletrônicos e geométricos. Neste trabalho, indicadores estruturais, como a extensão do sistema conjugado, são tratados como aproximações para a triagem de candidatos, e não como substitutos de um cálculo ou de uma medida espectroscópica.

### 2.1.3 Representações computacionais de moléculas

Moléculas podem ser representadas computacionalmente de várias formas, conforme o objetivo. No grafo molecular, átomos são nós e ligações são arestas, o que expressa explicitamente a conectividade. O SMILES descreve a estrutura por uma sequência de caracteres (WEININGER, 1988); apesar de compacto, depende da ordem de percurso da molécula, de modo que uma mesma molécula admite diferentes SMILES e as relações hierárquicas entre subestruturas não ficam explícitas.

Representações hierárquicas organizam a molécula em unidades de maior nível, como fragmentos, e, entre elas, as baseadas em árvores dispõem os componentes segundo a decomposição adotada. Como a molécula é originalmente um grafo, construir uma árvore exige definir quais elementos são preservados e como se relacionam; trata-se de uma abstração adequada à tarefa de comparação ou geração, e não de uma substituição do grafo molecular.

### 2.1.4 Tree Edit Distance

A *Tree Edit Distance* (TED) quantifica a diferença entre duas árvores pelo custo mínimo de uma sequência de operações de edição (inserção, remoção e substituição de nós) que transforma uma na outra. Aplicada a representações hierárquicas de moléculas, ela mede diferenças entre as organizações estruturais: moléculas que compartilham subestruturas tendem a ter menor distância, a depender da representação e dos custos adotados. A TED é uma medida de distância entre representações estruturais, e não uma medida direta de similaridade espectroscópica.

Zhang e Shasha (1989) propuseram um algoritmo de programação dinâmica para a distância de edição entre árvores ordenadas, que decompõe o problema em subproblemas menores. Neste trabalho o algoritmo é usado para calcular a TED entre as árvores dos anéis, normalizada pelo tamanho da maior árvore, e a distância obtida é o critério estrutural para selecionar o anel parceiro na recombinação.

## 2.2 ESTADO DA ARTE EM GERAÇÃO MOLECULAR

O JT-VAE (JIN; BARZILAY; JAAKKOLA, 2018) usa uma árvore de subestruturas químicas associada ao grafo molecular, separando a organização dos componentes da conectividade detalhada. Ishitani, Kataoka e Rikimaru (2022) propuseram uma representação em árvore reversível (*Reversible Junction Trees*) associada a aprendizado por reforço para otimização molecular, e Yamada e Sugiyama (2023) exploraram a decomposição e a recombinação de moléculas por estruturas hierárquicas e mecanismos de otimização. Essas abordagens mostram que subestruturas químicas funcionam como unidades de representação e modificação. Contudo, a representação hierárquica não define, por si só, como duas moléculas devem ser comparadas, e é aí que a TED se apresenta como critério explícito (GENHEDEN; ENKVIST; BJERRUM, 2021).

Mizrahi et al. (2025) é a principal influência conceitual deste trabalho. Embora tratem de receitas culinárias e de modelos de linguagem, os autores convertem cada receita em uma árvore (ingredientes como folhas e ações como nós internos) e aplicam o algoritmo de Zhang-Shasha para transformar a árvore de uma receita na de outra; as árvores intermediárias do caminho de edição são tomadas como novas receitas, que combinam elementos estruturais das duas origens. Os resultados indicam que essa recombinação

estruturada produz saídas mais diversas e mais novas do que a geração direta por LLM, com valor comparável. A adaptação proposta aqui difere da deles em pontos importantes. Aqui a árvore representa anéis, posições e fragmentos; o valor da TED é usado apenas para escolher o par de anéis a recombinar, e a molécula é obtida por junção química dos dois anéis por uma ponte, e não pelas árvores intermediárias do caminho de edição. A viabilidade química, que na origem é avaliada com o FlavorDB, é aqui uma restrição garantida por regras de valência e sanitização. Usar as árvores intermediárias como moléculas candidatas exigiria garantir a validade química de cada estado intermediário, e fica como possibilidade futura. Trata-se, portanto, de uma adaptação parcial da ideia, e não de uma transposição direta.

Fora das representações em árvore, Kwon et al. (2021) combinaram algoritmo genético, um decodificador RNN (LSTM) de SMILES e uma rede neural como substituta de cálculos TD-DFT, usada como função de aptidão de baixo custo e com re-treino iterativo para extrapolar além da distribuição de treino. Worakul et al. (2025) geraram materiais de fissão de singleto por aprendizado por reforço com preditor GNN (Chemprop) sobre uma base orientada a fragmentos. Para propriedades optoeletrônicas, há ainda fluxos de projeto inverso que alternam geração molecular, modelos substitutos e cálculos quânticos (YOO et al., 2023). Em comum, essas abordagens dependem de modelos treinados e fornecem pouco controle explícito sobre a origem estrutural de cada candidato.

## 2.3 SÍNTESE E LACUNAS

A Tabela 1 resume os trabalhos discutidos quanto à representação molecular, ao mecanismo de geração e ao critério que orienta a busca.

Tabela 1 – Comparação entre abordagens de geração molecular discutidas.

| Trabalho                            | Representação                                | Geração                                                                         | Critério de orientação                                       |
|-------------------------------------|----------------------------------------------|---------------------------------------------------------------------------------|--------------------------------------------------------------|
| Mizrahi et al. (2025)               | Árvore de receita (ingredientes e ações)     | Árvores intermediárias do caminho de edição de Zhang-Shasha entre duas receitas | Valor (compatibilidade) e novidade (inspirada em TF-IDF)     |
| Jin, Barzilay e Jaakkola (2018)     | Árvore de junção + grafo                     | VAE, espaço latente                                                             | Otimização no espaço latente                                 |
| Ishitani, Kataoka e Rikimaru (2022) | Árvore de junção reversível                  | Aprendizado por reforço                                                         | Função de recompensa                                         |
| Yamada e Sugiyama (2023)            | Subgrafos recorrentes                        | Decomposição e recombinação com RL                                              | Função de recompensa                                         |
| Kwon et al. (2021)                  | ECFP e SMILES                                | Algoritmo genético + RNN                                                        | Preditor substituto de TD-DFT                                |
| Worakul et al. (2025)               | Fragmentos                                   | RL com preditor GNN                                                             | Propriedade-alvo prevista                                    |
| Jensen (2019)                       | Grafo molecular                              | Algoritmo genético com <i>crossover</i> de fragmentos                           | Função de aptidão                                            |
| Krenn et al. (2020)                 | SELFIES (cadeia)                             | Qualquer método sobre a cadeia                                                  | Validade por construção                                      |
| <b>Este trabalho</b>                | Árvore por anel (anel → posição → fragmento) | Recombinação anel-ponte-anel                                                    | TED (Zhang-Shasha) entre anéis, mais indicador de conjugação |

Fonte: Elaborado pela autora.

Entre os métodos sem treinamento, Jensen (2019) propôs um algoritmo genético sobre grafos moleculares, com *crossover* que troca fragmentos entre moléculas-pai, e o

SELFIES (KRENN et al., 2020) é uma representação em cadeia na qual toda sequência corresponde a uma molécula válida. Ambos disputam o mesmo nicho que este trabalho: explorar o espaço químico sem depender de modelos treinados.

Observa-se que os métodos baseados em aprendizado dependem de treinamento, de funções de recompensa ou de preditores substitutos, e usam as árvores principalmente como representação, e não como critério de comparação entre moléculas. A distância de edição de árvores, por sua vez, já foi aplicada a estruturas químicas em tarefas de agrupamento de rotas sintéticas (GENHEDEN; ENGKVIST; BJERRUM, 2021), e a recombinação estruturada guiada por Zhang–Shasha foi demonstrada em receitas culinárias (MIZRAHI et al., 2025), mas não, até onde se pôde verificar nesta revisão, para selecionar parceiros em uma recombinação de fragmentos moleculares.

Disso decorrem as lacunas que este trabalho busca tratar, as mesmas retomadas na Introdução:

1. os métodos sem treinamento, baseados em recombinação direta de estruturas (JENSEN, 2019) ou em representações válidas por construção (KRENN et al., 2020), não usam, até onde se pôde verificar, uma distância explícita entre árvores para escolher os pares a recombinar;
2. a diversidade já é usada para guiar a geração em aprendizado por reforço, por meio de memória e filtros de diversidade (BLASCHKE et al., 2020), mas medida por similaridade de extitfingerprints, e não por uma distância entre organizações hierárquicas das moléculas;
3. um critério explícito de seleção torna cada candidato rastreável até os anéis e fragmentos de origem, o que o distingue dos métodos treinados, mas não do algoritmo genético de Jensen (2019), que também é rastreável; frente a ele, a diferença está no critério de seleção dos pares.

Esses métodos são os concorrentes diretos da proposta. Neste trabalho, o algoritmo genético de Jensen (2019) é o referencial natural de comparação, e a seleção aleatória de parceiros é o baseline mínimo (Capítulo 4). **3**

## JUSTIFICATIVA DA ESCOLHA METODOLÓGICA

### 3.1 POR QUE RECOMBINAÇÃO DE FRAGMENTOS E ÁRVORES

A recombinação de fragmentos sobre um catálogo finito garante, por construção, que cada molécula possa ser rastreada até os anéis, as pontes e os substituintes de origem, e dispensa bases de treinamento. Em contrapartida, a cobertura do espaço químico fica limitada ao catálogo, uma limitação reconhecida frente a modelos generativos treinados, que podem, em princípio, propor estruturas fora dele.

## 3.2 POR QUE A TED E NÃO OUTRAS MEDIDAS DE DISTÂNCIA

A medida de distância define quais pares de anéis são considerados distantes e, portanto, quais combinações são priorizadas. As alternativas mais evidentes são as seguintes.

- **Similaridade de Tanimoto sobre *fingerprints* (ECFP).** É barata e muito usada, mas é calculada sobre a presença de subestruturas locais e não sobre a organização entre elas. Neste trabalho, a representação por árvore já separa explicitamente esqueleto, posição e fragmento, e a TED registra diferenças em cada um desses níveis. O Tanimoto sobre ECFP continua sendo a métrica adequada para avaliar a diversidade da molécula final (Capítulo 4) e, por ser independente da árvore, evita avaliar o método com o mesmo critério que o orienta.
- **Distância de edição entre grafos (GED).** Opera diretamente sobre o grafo molecular, mas é NP-difícil no pior caso. Como o catálogo é finito, esse argumento não é decisivo: a matriz de distâncias entre anéis pode ser pré-calculada uma única vez (cerca de 7 minutos para a TED, com o catálogo provisório atual), de modo que a escolha entre TED e GED é prática e deve ser verificada empiricamente.
- **TED para árvores ordenadas (Zhang–Shasha).** Tem algoritmo polinomial (ZHANG; SHASHA, 1989; BILLE, 2005), ao contrário da versão para árvores não ordenadas, que é NP-difícil (ZHANG; STATMAN; SHASHA, 1992). O custo é a necessidade de uma ordenação canônica dos filhos de cada nó, tratada no Capítulo 5.

A escolha do algoritmo de Zhang–Shasha tem ainda como principal influência o trabalho de Mizrahi et al. (2025), em que a recombinação de árvores por distância de edição gera ideias mais diversas e novas do que a geração direta por modelos de linguagem. Essa evidência, obtida em outro domínio, motiva investigar se a mesma família de métodos favorece a diversidade na geração de moléculas, mas não a transfere diretamente: o uso aqui é diferente (Seção 2.2), e a comparação com o sorteio, com o sorteio pareado por tamanho, com a seleção por Tanimoto e com um limite superior de diversidade (braços A a E, Seção 5.6), além da verificação de que a distância entre anéis reflete a da molécula final, é o que permitirá dizer se a TED traz algum ganho.

### 3.3 LIMITAÇÕES RECONHECIDAS

A TED mede a distância entre as representações estruturais, e não entre espectros, e a distância entre dois anéis pode não refletir a distância entre as moléculas finais que os contêm (verificada na Seção 5.6). O indicador de conjugação usado como guia é uma triagem, e não uma previsão do comprimento de onda de absorção. Ambos os pontos são tratados como pontos a testar, e não como premissas.

4

## OBJETIVOS

### 4.1 OBJETIVO GERAL

Avaliar, por experimentos com baseline, controle de tamanho e ablação, se a seleção de parceiros por *Tree Edit Distance* (Zhang–Shasha) aumenta a diversidade estrutural de moléculas candidatas geradas por recombinação de fragmentos, e verificar se o indicador de conjugação usado como triagem se relaciona com a absorção UV-Vis calculada para um subconjunto.

### 4.2 OBJETIVOS ESPECÍFICOS

1. Construir um catálogo de fragmentos (anéis, substituintes e pontes) e um procedimento de recombinação na forma *anel-ponte-anel*;
2. Desenvolver uma representação em árvore de forma uniforme e com ordenação canônica para os anéis e seus substituintes, de modo que a distância não dependa da numeração arbitrária das posições;
3. Implementar a TED entre essas árvores pelo algoritmo de Zhang–Shasha e a regra de seleção de parceiros por maior distância sobre uma amostra;
4. Garantir a validade química dos candidatos por junção com verificação de valência, sanitização e aromatização, com novas tentativas e deduplicação, e medir o custo dessas tentativas;
5. Executar os braços A a E, com e sem guia de conjugação, segundo o plano estatístico, e avaliar o efeito da seleção por TED e o da guia de conjugação na diversidade;
6. Verificar se a TED do par de anéis se relaciona com a distância da molécula gerada;
7. Calcular o indicador de conjugação dos candidatos e validá-lo em um subconjunto por xTB/sTDA, com calibração por TD-DFT.

### 4.3 RELEVÂNCIA DA PESQUISA

A relevância desta pesquisa está em testar, com baseline, controle de tamanho, um concorrente sem árvore e um limite superior de diversidade, se uma distância explícita

entre árvores é um critério útil para escolher o que recombinar na geração de moléculas. Ao contrário de modelos generativos treinados, a recombinação por fragmentos permite rastrear cada molécula gerada até os anéis, as pontes e os substituintes de origem.

A contribuição esperada é a evidência, positiva ou negativa, sobre o uso da TED na exploração de um espaço químico restrito, com a separação entre o efeito da seleção, o da guia espectroscópica e o do pipeline de validade, e uma estimativa de quanto um indicador estrutural simples se relaciona com a absorção calculada.

## 5 METODOLOGIA PROPOSTA

### 5.1 VISÃO GERAL DO PIPELINE

### 5.2 GERAÇÃO DE FRAGMENTOS E COMBINAÇÃO

### 5.3 REPRESENTAÇÃO ESTRUTURAL (ÁRVORE/GRAFO)

### 5.4 AVALIAÇÃO DE DIVERSIDADE ESTRUTURAL

### 5.5 AMBIENTE E FERRAMENTAS

### 5.6 DELINEAMENTO EXPERIMENTAL

Os valores numéricos de tamanho de amostra, número de repetições e tolerâncias abaixo são propostas iniciais, a serem ajustadas após um estudo piloto. O tamanho do catálogo (hoje, 2152 anéis e 20 pontes) também é provisório, e todos os números derivados dele (número de combinações, custos, distribuição da TED) são medidas do catálogo atual, a refazer quando o catálogo final for definido.

#### 5.6.1 Regra de seleção de parceiros

Para cada anel-semente, sorteiam-se  $n_s = 10$  anéis do catálogo (sem reposição), calcula-se a TED normalizada entre a árvore do anel-semente e a de cada um e escolhe-se o de maior distância, com empates desfeitos ao acaso (argmax sobre a amostra). Por operar sobre uma amostra aleatória, e não sobre o catálogo inteiro, a regra limita a concentração de parceiros em poucos anéis periféricos (*hubness*), que ocorreria em um argmax global; a frequência de uso de cada anel como parceiro é registrada para verificar isso.

#### 5.6.2 Observação preliminar sobre a TED nas árvores atuais

Com um substituinte por anel ( $k = 1$ ), toda árvore tem 3 nós (anel, posição, fragmento) e, com custo unitário, a TED normalizada só assume os valores 0, 1/3, 2/3 e 1. Em 20 000 pares sorteados do catálogo provisório atual (2152 anéis), 60% tiveram distância 1, 37,5% distância 2/3 e 2,2% distância 1/3. Nessas condições, o “maior TED” discrimina pouco entre os parceiros e equivale, na prática, a contar quantos dos três componentes diferem; além disso, como todas as árvores têm o mesmo tamanho, o efeito de tamanho da TED (que é limitada inferiormente pela diferença entre os números de nós) não atua. Por isso, o teste principal do efeito da TED usa árvores com  $k = 3$  substituintes (as bases de origem têm até três fragmentos por anel), em que as árvores têm tamanhos diferentes e a distância é mais informativa, e o caso  $k = 1$  é reportado como controle.

#### 5.6.3 Braços do experimento

A Tabela 2 define os braços. Todos usam o mesmo catálogo, os mesmos anéis-semente, as mesmas pontes, o mesmo pipeline de junção e o mesmo número  $N$  de candidatos aceitos.

Tabela 2 – Braços do experimento (todos com mesmo  $N$ , mesmos anéis-semente e mesmo pipeline).

| Braço | Parceiro do anel-semente                                             | Papel                                    |
|-------|----------------------------------------------------------------------|------------------------------------------|
| A     | Sorteio uniforme                                                     | Baseline mínimo                          |
| B     | Sorteio pareado por tamanho de árvore                                | Controla o efeito de tamanho ( $k = 3$ ) |
| C     | Maior distância de Tanimoto (ECFP4 do anel) entre os $n_s$ sorteados | Concorrente simples, sem árvore          |
| D     | Maior TED entre os $n_s$ sorteados                                   | Proposta                                 |
| E     | MaxMin sobre o espaço enumerado (ou amostra grande dele)             | Limite superior de diversidade           |

Fonte: Elaborado pela autora.

Cruzam-se ainda os braços A e D com a guia de conjugação ligada e desligada (ablação), de modo que o efeito da seleção e o do *feedback* sejam separáveis. O espaço enumerado ( $\approx 9,3 \times 10^7$  combinações com  $k = 1$ ) serve de referência de cobertura. A geração de um candidato custa cerca de 3 ms nas medições atuais, de modo que enumerar o espaço completo custaria da ordem de 80 horas de CPU, e a matriz de TED entre todos os anéis (cerca de  $4,6 \times 10^6$  pares,  $\approx 0,2$  ms cada) leva cerca de 7 minutos. A justificativa para amostrar não é, portanto, o custo de gerar, mas o da avaliação de maior nível das moléculas (Seção 5.7), cujo custo por molécula deve ser medido no piloto.

#### 5.6.4 Métricas de avaliação

Para evitar circularidade (o braço C otimiza o Tanimoto sobre ECFP4 e ganharia trivialmente por essa métrica), a diversidade é avaliada por várias medidas independentes do critério de seleção: diversidade interna por Tanimoto sobre ECFP4 e sobre *atom-pair* (média de 1 – similaridade entre pares), número de esqueletos de Bemis–Murcko distintos, e cobertura do espaço enumerado (fração de esqueletos e de pares anel-base distintos atingida). *Válida* é a molécula que passa na sanitização do RDKit com valência correta; a validade é uma restrição do pipeline, e não efeito da seleção, e o número de novas tentativas por candidato é reportado como custo. *Nova* é a molécula cujo SMILES canônico não consta da base de origem do catálogo nem de um banco público (PubChem, consultado por InChIKey), comparação obrigatória. O indicador de conjugação é o número de átomos pesados no maior sistema conjugado (tamanho absoluto, e não fração), pois o deslocamento da absorção depende da extensão da conjugação, e não da proporção dela na molécula.

#### 5.6.5 Plano estatístico

Cada braço gera  $N = 1000$  candidatos, com  $R = 30$  repetições, cada uma com uma *seed* distinta do gerador de números aleatórios, e as comparações são feitas sempre a  $N$  igual, pois a diversidade interna depende do tamanho do conjunto. Usa-se o teste de Mann–Whitney (bilateral) sobre as  $R$  medidas por braço, com  $\alpha = 0,05$  e correção de Holm para as comparações múltiplas, e o tamanho de efeito é reportado pelo  $\delta$  de Cliff. A diferença mínima de interesse na diversidade interna é de 0,02 (escala de 1 – Tanimoto), definida *a priori* e a ser calibrada no piloto.

### 5.6.6 Critérios de avaliação

**Efeito da TED.** Com  $k = 3$ , o braço D tem diversidade interna maior do que os braços A e B por pelo menos 0,02, em todas as métricas independentes do critério. *Resultado desfavorável:* diferença menor que 0,02 ou não significativa para A ou B, ou ganho que desaparece em B (artefato de tamanho). *Evidência:* tabela de diversidade por braço, com testes, e gráfico de caixas por métrica.

**Mecanismo.** A TED entre o anel-semente e o parceiro correlaciona-se com a distância de Tanimoto (ECFP4) entre a molécula gerada e o anel-semente, controlando-se a ponte. Usa-se Spearman, e conta-se como positiva  $\rho \geq 0,3$  com intervalo de confiança de 95% (*bootstrap*) que exclua zero. *Resultado desfavorável:*  $\rho < 0,3$  ou intervalo que inclua zero. *Evidência:* gráfico de dispersão (TED  $\times$  distância final) por ponte, com o  $\rho$  e seu intervalo.

**Efeito da guia.** A guia aumenta o indicador médio de conjugação sem reduzir a diversidade interna em mais de 0,02 em relação ao mesmo braço sem guia. *Resultado desfavorável:* queda de diversidade maior que 0,02, ou ausência de aumento do indicador. *Evidência:* tabela da ablação (seleção  $\times$  guia).

## 5.7 VALIDAÇÃO ESPECTROSCÓPICA

O indicador de conjugação é uma triagem e não prevê o comprimento de onda de absorção, que depende também de efeitos doador–aceitador, planaridade e substituintes, e da intensidade da banda, não apenas da energia da transição. Propõe-se validar um subconjunto de 200 moléculas, estratificado em quintis do indicador (40 por quintil), com geometrias otimizadas por xTB (GFN2) e espectros por sTDA-xTB, obtendo-se o comprimento de onda de maior absorção e a força do oscilador. Em 20 dessas moléculas, os resultados serão calibrados por TD-DFT (funcional e base a definir). A métrica é a correlação de Spearman entre o indicador e cada uma dessas duas grandezas. Sem essa validação, os candidatos são descritos apenas como tendo “indicadores favoráveis” à absorção, e não como absorvedores comprovados.

## 6 RESULTADOS PRELIMINARES

6.1 INFRAESTRUTURA DE GERAÇÃO IMPLEMENTADA

6.2 DIVERSIDADE ESTRUTURAL OBSERVADA

6.3 LIMITAÇÕES OBSERVADAS E PRÓXIMOS PASSOS

## 7 CRONOGRAMA

Tabela 3 – Cronograma de atividades previstas.

| Atividade | T1 | T2 | T3 | T4 | T5 | T6 | T7 | T8 |
|-----------|----|----|----|----|----|----|----|----|
|-----------|----|----|----|----|----|----|----|----|

Fonte: Elaborado pelo autor.

## REFERÊNCIAS

- ATKINS, P.; PAULA, J. de. **Atkins' physical chemistry**. 11. ed. Oxford: Oxford University Press, 2018.
- BILLE, P. A survey on tree edit distance and related problems. **Theoretical Computer Science**, v. 337, n. 1–3, p. 217–239, 2005.
- BLASCHKE, T. et al. REINVENT 2.0: an AI tool for de novo drug design. **Journal of Chemical Information and Modeling**, v. 60, n. 12, p. 5918–5922, 2020.
- BOHACEK, R. S.; MCMARTIN, C.; GUIDA, W. C. The art and practice of structure-based drug design: a molecular modeling perspective. **Medicinal Research Reviews**, v. 16, n. 1, p. 3–50, 1996.
- CAO, N. D.; KIPF, T. **MolGAN: an implicit generative model for small molecular graphs**. 2018. ArXiv:1805.11973.
- GENHEDEN, S.; ENGKVIST, O.; BJERRUM, E. Clustering of synthetic routes using tree edit distance. **Journal of Chemical Information and Modeling**, v. 61, n. 8, p. 3899–3907, 2021.
- GÓMEZ-BOMBARELLI, R. et al. Automatic chemical design using a data-driven continuous representation of molecules. **ACS Central Science**, v. 4, n. 2, p. 268–276, 2018.
- GUIMARAES, G. L. et al. **Objective-reinforced generative adversarial networks (ORGAN) for sequence generation models**. 2017. ArXiv:1705.10843.
- ISHITANI, R.; KATAOKA, T.; RIKIMARU, K. Molecular design method using a reversible tree representation of chemical compounds and deep reinforcement learning. **Journal of Chemical Information and Modeling**, v. 62, n. 17, p. 4032–4048, 2022.
- JENSEN, J. H. A graph-based genetic algorithm and generative model/Monte Carlo tree search for the exploration of chemical space. **Chemical Science**, v. 10, n. 12, p. 3567–3572, 2019.
- JIN, W.; BARZILAY, R.; JAAKKOLA, T. Junction tree variational autoencoder for molecular graph generation. In: **Proceedings of the 35th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2018. (PMLR, v. 80), p. 2323–2332.
- KRENN, M. et al. Self-referencing embedded strings (SELFIES): a 100% robust molecular string representation. **Machine Learning: Science and Technology**, v. 1, n. 4, p. 045024, 2020.
- KWON, Y. et al. Evolutionary design of molecules based on deep learning and a genetic algorithm. **Scientific Reports**, v. 11, p. 17304, 2021.
- MAMEDE, R.; PEREIRA, F.; SOUSA, J. Aires-de. Machine learning prediction of UV–Vis spectra features of organic compounds related to photoreactive potential. **Scientific Reports**, v. 11, p. 23720, 2021.

- MIZRAHI, M. et al. **Cooking up creativity: enhancing LLM creativity through structured recombination**. 2025. ArXiv:2504.20643.
- OLIVECRONA, M. et al. Molecular de-novo design through deep reinforcement learning. **Journal of Cheminformatics**, v. 9, p. 48, 2017.
- OSTROVERKHOVA, O. Organic optoelectronic materials: mechanisms and applications. **Chemical Reviews**, v. 116, n. 22, p. 13279–13412, 2016.
- PAVIA, D. L. et al. **Introduction to spectroscopy**. 5. ed. Stamford: Cengage Learning, 2015.
- POLISHCHUK, P. G.; MADZHIDOV, T. I.; VARNEK, A. Estimation of the size of drug-like chemical space based on GDB-17 data. **Journal of Computer-Aided Molecular Design**, v. 27, n. 8, p. 675–679, 2013.
- ROCHA, F. S. et al. Experimental methods in chemical engineering: ultraviolet visible spectroscopy – UV-Vis. **The Canadian Journal of Chemical Engineering**, v. 96, n. 12, p. 2512–2517, 2018.
- ROJAS, F. S.; OJEDA, C. B. Recent development in derivative ultraviolet/visible absorption spectrophotometry: 2004–2008: a review. **Analytica Chimica Acta**, v. 635, n. 1, p. 22–44, 2009.
- SILVERSTEIN, R. M.; WEBSTER, F. X.; KIEMLE, D. J. **Spectrometric identification of organic compounds**. 7. ed. Hoboken: Wiley, 2005.
- SKOOG, D. A.; HOLLER, F. J.; CROUCH, S. R. **Principles of instrumental analysis**. 7. ed. Boston: Cengage Learning, 2017.
- TKATCHENKO, A. Machine learning for chemical discovery. **Nature Communications**, v. 11, p. 4125, 2020.
- WEININGER, D. SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. **Journal of Chemical Information and Computer Sciences**, v. 28, n. 1, p. 31–36, 1988.
- WORAKUL, T. et al. Generative design of singlet fission materials leveraging a fragment-oriented database. **Chemical Science**, v. 16, p. 17956–17969, 2025.
- YAMADA, M.; SUGIYAMA, M. Molecular graph generation by decomposition and reassembling. **ACS Omega**, v. 8, n. 22, p. 19575–19586, 2023.
- YOO, P. et al. Deep learning workflow for the inverse design of molecules with specific optoelectronic properties. **Scientific Reports**, v. 13, p. 20031, 2023.
- YOU, J. et al. Graph convolutional policy network for goal-directed molecular graph generation. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2018. v. 31.
- ZHANG, K.; SHASHA, D. Simple fast algorithms for the editing distance between trees and related problems. **SIAM Journal on Computing**, v. 18, n. 6, p. 1245–1262, 1989.
- ZHANG, K.; STATMAN, R.; SHASHA, D. On the editing distance between unordered labeled trees. **Information Processing Letters**, v. 42, n. 3, p. 133–139, 1992.