

Crhisângela G. R. Ferreira

**Geração combinatória de moléculas via
recombinação de fragmentos representados em
SMILES**

Santo André, SP

2026

Crhisângela G. R. Ferreira

Geração combinatória de moléculas via recombinação de fragmentos representados em SMILES

Exame de qualificação apresentado ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal do ABC como parte dos requisitos para obtenção do título de Mestre em Ciência da Computação.

Universidade Federal do ABC – UFABC
Programa de Pós-Graduação em Ciência da Computação

Orientador Prof. Dr. Jesús P. Mena-Chalco
Coorientador Prof. Dr. Mauricio Coutinho

Santo André, SP
2026

PORTUGUÊS

Palavras-chave: palavra 1. palavra 2. palavra 3.

ENGLISH

Keywords: keyword 1. keyword 2. keyword 3.

LISTA DE ILUSTRAÇÕES

LISTA DE TABELAS

Tabela 1 – Comparação entre abordagens de geração molecular discutidas.	14
Tabela 2 – Cronograma de atividades previstas.	21

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
PPG	Programa de Pós-Graduação
SMILES	Simplified Molecular Input Line Entry System
QSAR	Quantitative Structure-Activity Relationship
UFABC	Universidade Federal do ABC
ZSA	Algoritmo de Zhang-Shasha (<i>Zhang-Shasha Algorithm</i>)

SUMÁRIO

1	INTRODUÇÃO	9
1.1	Contextualização e motivação	9
1.2	Definição do problema	10
1.2.0.0.1	Problema.	10
1.2.0.0.2	Dimensão do espaço de busca.	10
1.2.0.0.3	Proposta de solução.	10
1.2.0.0.4	Objetivo e contribuições esperadas.	11
2	REVISÃO DE LITERATURA	12
2.1	Fundamentos	12
2.1.1	Espectroscopia UV-Vis	12
2.1.2	Relação entre estrutura molecular e absorção UV-Vis	12
2.1.3	Representações computacionais de moléculas	13
2.1.4	Tree Edit Distance	13
2.2	Estado da arte em geração molecular	13
2.3	Síntese e lacunas	14
3	JUSTIFICATIVA DA ESCOLHA METODOLÓGICA	15
3.1	Por que recombinação de fragmentos e árvores	15
3.2	Por que a TED e não outras medidas de distância	15
3.3	Limitações reconhecidas	16
4	OBJETIVOS	16
4.1	Hipótese	16
4.1.0.0.1	Definições operacionais.	17
4.1.0.0.2	Escopo da avaliação espectroscópica.	17
4.2	Objetivo geral	17
4.3	Objetivos específicos	17
4.4	Relevância da pesquisa	18
5	METODOLOGIA PROPOSTA	19
5.1	Visão geral do pipeline	19
5.2	Geração de fragmentos e combinação	19
5.3	Representação estrutural (árvore/grafos)	19
5.4	Avaliação de diversidade estrutural	19
5.5	Ambiente e ferramentas	19
6	RESULTADOS PRELIMINARES	20
6.1	Infraestrutura de geração implementada	20
6.2	Diversidade estrutural observada	20
6.3	Limitações observadas e próximos passos	20
7	CRONOGRAMA	21

REFERÊNCIAS 22

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

Moléculas que absorvem radiação ultravioleta (UV) e visível (Vis) são importantes em diversos setores: no monitoramento de contaminantes e de processos de fotodegradação em água e na quantificação de fármacos (ROCHA et al., 2018), e em células solares orgânicas e OLEDs (OSTROVERKHOVA, 2016). A capacidade de uma molécula de absorver radiação em determinadas regiões do espectro está relacionada à sua estrutura molecular e às características eletrônicas dela decorrentes (ATKINS; PAULA, 2018; SILVERSTEIN; WEBSTER; KIEMLE, 2005). Identificar e desenvolver moléculas com propriedades ópticas específicas é, portanto, um problema de interesse em Química e em Ciência de Materiais.

Encontrar novos compostos com propriedades de interesse é difícil devido à extensão do espaço químico: Polishchuk, Madzhidov e Varnek (2013) estimaram em cerca de 10^{33} as estruturas compatíveis com moléculas *drug-like*, e Bohacek, McMartin e Guida (1996) em ordem de 10^{60} as moléculas orgânicas pequenas, valores que dependem do critério de contagem adotado. Esses números descrevem o espaço químico geral, e não o espaço de busca deste trabalho, que é restrito a um catálogo finito de fragmentos (Seção 1.2). Eles motivam, porém, estratégias computacionais que restrinjam a busca a regiões associadas a propriedades específicas (TKATCHENKO, 2020). Na própria espectroscopia UV-Vis, métodos de aprendizado de máquina já são usados para prever características de espectros a partir da estrutura (MAMEDE; PEREIRA; SOUSA, 2021).

Diferentes abordagens têm sido empregadas na geração e na otimização de moléculas, entre elas autoencoders variacionais (GÓMEZ-BOMBARELLI et al., 2018; JIN; BARZILAY; JAAKKOLA, 2018), redes adversárias generativas (GUIMARAES et al., 2017; CAO; KIPF, 2018), aprendizado por reforço (OLIVECRONA et al., 2017; YOU et al., 2018) e arquiteturas híbridas que combinam algoritmos genéticos, redes recorrentes e modelos substitutos de cálculos quânticos (KWON et al., 2021). Os métodos baseados em redes neurais costumam depender de bases de dados para treinamento e de modelos de propriedades, e a origem estrutural de cada molécula gerada nem sempre é explícita. Além disso, o resultado depende da representação molecular adotada (*strings*, *fingerprints* ou grafos), pois ela determina quais modificações estruturais são possíveis, se a validade química é preservada e como a similaridade entre moléculas é medida.

Representações lineares, como o SMILES, descrevem estruturas de forma compacta e são amplamente usadas em modelos generativos (WEININGER, 1988; GÓMEZ-BOMBARELLI et al., 2018), mas a representação sequencial não explicita as relações hierárquicas entre subestruturas, e moléculas relacionadas podem ter representações distintas (JIN; BARZILAY; JAAKKOLA, 2018). Como alternativa, trabalhos recentes adotam representações hierárquicas baseadas em subestruturas. O *Junction Tree Variational Autoencoder* (JT-VAE) usa uma árvore de subestruturas para gerar moléculas válidas (JIN; BARZILAY; JAAKKOLA, 2018), e abordagens posteriores combinaram árvores com aprendizado por reforço e com decomposição e recombinação molecular (ISHITANI; KATAOKA; RIKIMARU, 2022; YAMADA; SUGIYAMA, 2023).

Em paralelo, métodos sem treinamento exploram o espaço por recombinação direta de estruturas, como os algoritmos genéticos sobre grafos moleculares com *crossover* de

fragmentos (JENSEN, 2019), e há representações que garantem validade por construção, como o SELFIES (KRENN et al., 2020). Até onde se pôde verificar nesta revisão, porém, nesses métodos a escolha dos pares a recombinar não é feita por uma medida explícita de distância entre as organizações hierárquicas das moléculas, que permitiria controlar o quão distantes entre si são as estruturas combinadas.

A *Tree Edit Distance* (TED) quantifica a diferença entre duas árvores pelo custo mínimo de operações de edição sobre nós. Sua versão para árvores ordenadas tem algoritmo polinomial (ZHANG; SHASHA, 1989; BILLE, 2005), enquanto a versão para árvores não ordenadas é NP-difícil (ZHANG; STATMAN; SHASHA, 1992); a distância de edição entre grafos gerais também é NP-difícil, o que a torna menos adequada à comparação repetida de muitos pares. A TED já foi aplicada a estruturas químicas, no agrupamento de rotas sintéticas (GENHEDEN; ENGVIST; BJERRUM, 2021). Em outro domínio, Mizrahi et al. (2025) representam receitas culinárias como árvores e usam o algoritmo de Zhang–Shasha para recombina-las, obtendo saídas mais diversas e mais novas do que a geração direta por modelos de linguagem. Essa evidência motiva o uso da TED neste trabalho, cuja aplicação, como discutido na Seção 2.3, difere da deles.

1.2 DEFINIÇÃO DO PROBLEMA

1.2.0.0.1 Problema.

Dado um catálogo finito de fragmentos (anéis, substituintes e pontes conjugadas) e a restrição de que cada molécula gerada seja quimicamente válida, como explorar o espaço de moléculas *anel–ponte–anel* de modo a obter um conjunto de candidatos novos, estruturalmente diversos e com indicadores favoráveis à absorção UV-Vis?

1.2.0.0.2 Dimensão do espaço de busca.

O catálogo atual tem 2152 anéis únicos, formados a partir de 48 esqueletos e 26 substituintes, e 20 pontes, o que dá cerca de $2152 \times 2151 \times 20 \approx 9,3 \times 10^7$ combinações ordenadas, antes de contar as escolhas de átomo de encaixe. Esse espaço é enumerável, mas cresce rapidamente com o número de substituintes por anel e com o tamanho do catálogo, e cada candidato exige junção, sanitização e avaliação. Interessa, portanto, uma estratégia de seleção que favoreça a diversidade da amostra gerada, em vez de depender de enumeração ou de sorteio uniforme.

1.2.0.0.3 Proposta de solução.

Propõe-se representar cada anel e seus substituintes como uma árvore ordenada de forma uniforme (anel $\rightarrow$ posição $\rightarrow$ fragmento) e usar a TED de Zhang–Shasha para escolher o anel parceiro de cada anel-semente, priorizando parceiros estruturalmente distantes. A validade química não é atribuída à TED: é uma restrição garantida por junção com verificação de valência, sanitização e aromatização, e a taxa de novas tentativas é tratada como medida de custo. Um indicador de conjugação pode, adicionalmente, orientar a escolha das pontes nas gerações seguintes.

1.2.0.0.4 Objetivo e contribuições esperadas.

O objetivo é investigar se a seleção de parceiros por TED aumenta a diversidade estrutural dos candidatos em relação a uma seleção aleatória, mantendo-os válidos e novos. As contribuições esperadas são: (i) um procedimento de recombinação de fragmentos orientado por distância entre árvores, com origem rastreável de cada molécula; (ii) uma comparação com baseline e uma ablação dos dois mecanismos de orientação; e (iii) uma triagem dos candidatos por conjugação, tratada como indicador aproximado, e não como previsão espectroscópica. Hipótese, definições operacionais e objetivos específicos estão no Capítulo 4.

2 REVISÃO DE LITERATURA

2.1 FUNDAMENTOS

2.1.1 Espectroscopia UV-Vis

A espectroscopia é o estudo da interação entre a radiação eletromagnética e a matéria. A espectroscopia de absorção UV-Vis baseia-se na capacidade de certas moléculas absorverem radiação nas regiões ultravioleta e visível, em uma faixa aproximadamente entre 190 e 800 nm, cujos limites variam com o instrumento e a aplicação (ROCHA et al., 2018; ROJAS; OJEDA, 2009).

A absorção ocorre quando a energia da radiação incidente é suficiente para promover uma transição eletrônica entre estados de diferentes energias. Em uma descrição por orbitais moleculares, uma dessas transições pode ser associada à promoção de um elétron do orbital molecular ocupado de maior energia (HOMO) para o orbital desocupado de menor energia (LUMO) (PAVIA et al., 2015; ATKINS; PAULA, 2018). A relação entre a diferença de energia e o comprimento de onda absorvido é

$$E = \frac{hc}{\lambda}, \quad (2.1)$$

em que E é a energia da radiação, h a constante de Planck, c a velocidade da luz e λ o comprimento de onda. Menores diferenças de energia entre os estados eletrônicos correspondem, portanto, a maiores comprimentos de onda de absorção. Os grupos responsáveis pela absorção são denominados cromóforos (PAVIA et al., 2015; SKOOG; HOLLER; CROUCH, 2017).

2.1.2 Relação entre estrutura molecular e absorção UV-Vis

A estrutura molecular influencia a absorção ao modificar a distribuição eletrônica e as energias das transições. Entre as características relevantes estão a extensão da conjugação, a presença de grupos auxocrômicos e a existência de sistemas aromáticos.

Sistemas conjugados são formados por ligações simples e duplas alternadas que deslocalizam os elétrons π ; o aumento da conjugação reduz a diferença de energia entre os estados envolvidos e desloca o máximo de absorção para maiores comprimentos de onda (PAVIA et al., 2015; SKOOG; HOLLER; CROUCH, 2017). Os auxocromos, quando ligados a um cromóforo, podem alterar a intensidade e a posição das bandas, devido aos pares de elétrons livres que interagem com o sistema eletrônico. Anéis aromáticos, em especial os fusionados, podem absorver em maiores comprimentos de onda pela maior deslocalização, embora a geometria (por exemplo, a planaridade) também influencie a sobreposição dos orbitais.

Dessa forma, a conectividade molecular fornece informação relevante, mas não descreve isoladamente o comportamento espectroscópico, que depende também de fatores eletrônicos e geométricos. Neste trabalho, indicadores estruturais, como a extensão do sistema conjugado, são tratados como aproximações para a triagem de candidatos, e não como substitutos de um cálculo ou de uma medida espectroscópica.

2.1.3 Representações computacionais de moléculas

Moléculas podem ser representadas computacionalmente de várias formas, conforme o objetivo. No grafo molecular, átomos são nós e ligações são arestas, o que expressa explicitamente a conectividade. O SMILES descreve a estrutura por uma sequência de caracteres (WEININGER, 1988); apesar de compacto, depende da ordem de percurso da molécula, de modo que uma mesma molécula admite diferentes SMILES e as relações hierárquicas entre subestruturas não ficam explícitas.

Representações hierárquicas organizam a molécula em unidades de maior nível, como fragmentos, e, entre elas, as baseadas em árvores dispõem os componentes segundo a decomposição adotada. Como a molécula é originalmente um grafo, construir uma árvore exige definir quais elementos são preservados e como se relacionam; trata-se de uma abstração adequada à tarefa de comparação ou geração, e não de uma substituição do grafo molecular.

2.1.4 Tree Edit Distance

A *Tree Edit Distance* (TED) quantifica a diferença entre duas árvores pelo custo mínimo de uma sequência de operações de edição (inserção, remoção e substituição de nós) que transforma uma na outra. Aplicada a representações hierárquicas de moléculas, ela mede diferenças entre as organizações estruturais: moléculas que compartilham subestruturas tendem a ter menor distância, a depender da representação e dos custos adotados. A TED é uma medida de distância entre representações estruturais, e não uma medida direta de similaridade espectroscópica.

Zhang e Shasha (1989) propuseram um algoritmo de programação dinâmica para a distância de edição entre árvores ordenadas, que decompõe o problema em subproblemas menores. Neste trabalho o algoritmo é usado para calcular a TED entre as árvores dos anéis, normalizada pelo tamanho da maior árvore, e a distância obtida é o critério estrutural para selecionar o anel parceiro na recombinação.

2.2 ESTADO DA ARTE EM GERAÇÃO MOLECULAR

O JT-VAE (JIN; BARZILAY; JAAKKOLA, 2018) usa uma árvore de subestruturas químicas associada ao grafo molecular, separando a organização dos componentes da conectividade detalhada. Ishitani, Kataoka e Rikimaru (2022) propuseram uma representação em árvore reversível (*Reversible Junction Trees*) associada a aprendizado por reforço para otimização molecular, e Yamada e Sugiyama (2023) exploraram a decomposição e a recombinação de moléculas por estruturas hierárquicas e mecanismos de otimização. Essas abordagens mostram que subestruturas químicas funcionam como unidades de representação e modificação. Contudo, a representação hierárquica não define, por si só, como duas moléculas devem ser comparadas, e é aí que a TED se apresenta como critério explícito (GENHEDEN; ENKVIST; BJERRUM, 2021).

Mizrahi et al. (2025) é a principal influência conceitual deste trabalho. Embora tratem de receitas culinárias e de modelos de linguagem, os autores convertem cada receita em uma árvore (ingredientes como folhas e ações como nós internos) e aplicam o algoritmo de Zhang-Shasha para transformar a árvore de uma receita na de outra; as árvores intermediárias do caminho de edição são tomadas como novas receitas, que combinam elementos estruturais das duas origens. Os resultados indicam que essa recombinação

estruturada produz saídas mais diversas e mais novas do que a geração direta por LLM, com valor comparável. A adaptação proposta aqui difere da deles em pontos importantes. Aqui a árvore representa anéis, posições e fragmentos; o valor da TED é usado apenas para escolher o par de anéis a recombinar, e a molécula é obtida por junção química dos dois anéis por uma ponte, e não pelas árvores intermediárias do caminho de edição. A viabilidade química, que na origem é avaliada com o FlavorDB, é aqui uma restrição garantida por regras de valência e sanitização. Usar as árvores intermediárias como moléculas candidatas exigiria garantir a validade química de cada estado intermediário, e fica como possibilidade futura. Trata-se, portanto, de uma adaptação parcial da ideia, e não de uma transposição direta.

Fora das representações em árvore, Kwon et al. (2021) combinaram algoritmo genético, um decodificador RNN (LSTM) de SMILES e uma rede neural como substituta de cálculos TD-DFT, usada como função de aptidão de baixo custo e com re-treino iterativo para extrapolar além da distribuição de treino. Worakul et al. (2025) geraram materiais de fissão de singleto por aprendizado por reforço com preditor GNN (Chemprop) sobre uma base orientada a fragmentos. Para propriedades optoeletrônicas, há ainda fluxos de projeto inverso que alternam geração molecular, modelos substitutos e cálculos quânticos (YOO et al., 2023). Em comum, essas abordagens dependem de modelos treinados e fornecem pouco controle explícito sobre a origem estrutural de cada candidato.

2.3 SÍNTESE E LACUNAS

A Tabela 1 resume os trabalhos discutidos quanto à representação molecular, ao mecanismo de geração e ao critério que orienta a busca.

Tabela 1 – Comparação entre abordagens de geração molecular discutidas.

Trabalho	Representação	Geração	Critério de orientação
Mizrahi et al. (2025)	Árvore de receita (ingredientes e ações)	Árvores intermediárias do caminho de edição de Zhang-Shasha entre duas receitas	Valor (compatibilidade) e novidade (inspirada em TF-IDF)
Jin, Barzilay e Jaakkola (2018)	Árvore de junção + grafo	VAE, espaço latente	Otimização no espaço latente
Ishitani, Kataoka e Rikimaru (2022)	Árvore de junção reversível	Aprendizado por reforço	Função de recompensa
Yamada e Sugiyama (2023)	Subgrafos recorrentes	Decomposição e recombinação com RL	Função de recompensa
Kwon et al. (2021)	ECFP e SMILES	Algoritmo genético + RNN	Preditor substituto de TD-DFT
Worakul et al. (2025)	Fragmentos	RL com preditor GNN	Propriedade-alvo prevista
Jensen (2019)	Grafo molecular	Algoritmo genético com <i>crossover</i> de fragmentos	Função de aptidão
Krenn et al. (2020)	SELFIES (cadeia)	Qualquer método sobre a cadeia	Validade por construção
Este trabalho	Árvore por anel (anel → posição → fragmento)	Recombinação anel-ponte-anel	TED (Zhang-Shasha) entre anéis, mais indicador de conjugação

Fonte: Elaborado pela autora.

Entre os métodos sem treinamento, Jensen (2019) propuseram um algoritmo genético sobre grafos moleculares, com *crossover* que troca fragmentos entre moléculas-pai,

e o SELFIES (KRENN et al., 2020) é uma representação em cadeia na qual toda sequência corresponde a uma molécula válida. Ambos disputam o mesmo nicho que este trabalho: explorar o espaço químico sem depender de modelos treinados.

Observa-se que os métodos baseados em aprendizado dependem de treinamento, de funções de recompensa ou de preditores substitutos, e usam as árvores principalmente como representação, e não como critério de comparação entre moléculas. A distância de edição de árvores, por sua vez, já foi aplicada a estruturas químicas em tarefas de agrupamento de rotas sintéticas (GENHEDEN; ENGKVIST; BJERRUM, 2021), e a recombinação estruturada guiada por Zhang–Shasha foi demonstrada em receitas culinárias (MIZRAHI et al., 2025), mas não, até onde se pôde verificar nesta revisão, para selecionar parceiros em uma recombinação de fragmentos moleculares.

Disso decorrem as lacunas que este trabalho busca tratar, as mesmas retomadas na Introdução:

1. os métodos sem treinamento, baseados em recombinação direta de estruturas (JENSEN, 2019) ou em representações válidas por construção (KRENN et al., 2020), não usam, até onde se pôde verificar, uma distância explícita entre árvores para escolher os pares a recombinar;
2. a diversidade estrutural do conjunto gerado costuma ser avaliada *a posteriori*, e não usada para guiar a geração;
3. com um critério explícito de seleção, cada candidato pode ser rastreado até os anéis e fragmentos de origem, o que é pouco explorado nos métodos treinados.

Esses métodos são os concorrentes diretos da proposta. Neste trabalho, o algoritmo genético de Jensen (2019) é o referencial natural de comparação, e a seleção aleatória de parceiros é o baseline mínimo (Capítulo 4). **3**

JUSTIFICATIVA DA ESCOLHA METODOLÓGICA

3.1 POR QUE RECOMBINAÇÃO DE FRAGMENTOS E ÁRVORES

A recombinação de fragmentos sobre um catálogo finito garante, por construção, que cada molécula possa ser rastreada até os anéis, as pontes e os substituintes de origem, e dispensa bases de treinamento. Em contrapartida, a cobertura do espaço químico fica limitada ao catálogo, uma limitação reconhecida frente a modelos generativos treinados, que podem, em princípio, propor estruturas fora dele.

3.2 POR QUE A TED E NÃO OUTRAS MEDIDAS DE DISTÂNCIA

A medida de distância define quais pares de anéis são considerados distantes e, portanto, quais combinações são priorizadas. As alternativas mais evidentes são as seguintes.

- **Similaridade de Tanimoto sobre *fingerprints* (ECFP).** É barata e muito usada, mas é calculada sobre a presença de subestruturas locais e não sobre a organização entre elas. Neste trabalho, a representação por árvore já separa explicitamente esqueleto, posição e fragmento, e a TED registra diferenças em cada um desses níveis. O Tanimoto sobre ECFP continua sendo a métrica adequada para avaliar a diversidade da molécula final (Capítulo 4) e, por ser independente da árvore, evita avaliar o método com o mesmo critério que o orienta.
- **Distância de edição entre grafos (GED).** Opera diretamente sobre o grafo molecular, mas é NP-difícil em geral, o que a torna pouco prática para comparar muitos pares de anéis a cada geração.
- **TED para árvores ordenadas (Zhang–Shasha).** Tem algoritmo polinomial (ZHANG; SHASHA, 1989; BILLE, 2005), ao contrário da versão para árvores não ordenadas, que é NP-difícil (ZHANG; STATMAN; SHASHA, 1992). O custo é a necessidade de uma ordenação canônica dos filhos de cada nó, tratada no Capítulo 5.

A escolha do algoritmo de Zhang–Shasha tem ainda como principal influência o trabalho de Mizrahi et al. (2025), em que a recombinação de árvores por distância de edição gera ideias mais diversas e novas do que a geração direta por modelos de linguagem. Essa evidência, obtida em outro domínio, motiva investigar se a mesma família de métodos favorece a diversidade na geração de moléculas, mas não a transfere diretamente: o uso aqui é diferente (Seção 2.2), e a comparação com o Tanimoto e com a seleção aleatória, nas hipóteses H1 e H2, é o que permitirá dizer se a TED traz algum ganho.

3.3 LIMITAÇÕES RECONHECIDAS

A TED mede a distância entre as representações estruturais, e não entre espectros, e a distância entre dois anéis pode não refletir a distância entre as moléculas finais que os contêm (hipótese H2). O indicador de conjugação usado como guia é uma triagem, e não uma previsão do comprimento de onda de absorção. Ambos os pontos são tratados como hipóteses a testar, e não como premissas.

4

OBJETIVOS

4.1 HIPÓTESE

A hipótese central é que, na recombinação de fragmentos *anel–ponte–anel*, escolher como parceiro de cada anel-semente o anel de maior *Tree Edit Distance* (TED) aumenta a diversidade estrutural dos candidatos em relação à escolha aleatória de parceiros. Ela se desdobra em três hipóteses testáveis, cada uma com o resultado que a refutaria.

H1 (efeito da TED). Com o mesmo catálogo, as mesmas sementes, o mesmo número de candidatos e a mesma guia de pontes, a seleção por TED máxima produz maior

diversidade interna do conjunto gerado do que a seleção aleatória de parceiros. *Refutação*: diferença não significativa, ou favorável ao sorteio, em repetições com sementes aleatórias distintas.

H2 (a distância entre anéis reflete a da molécula). A TED entre os anéis de um par se correlaciona positivamente com a distância estrutural entre a molécula gerada e as moléculas já obtidas (por exemplo, a distância de Tanimoto sobre ECFP4 ao vizinho mais próximo). *Refutação*: correlação nula ou negativa, o que indicaria que a distância entre anéis não é um bom critério para a diversidade da molécula final.

H3 (efeito da guia de conjugação). A guia por indicador de conjugação aumenta o valor médio do indicador nos candidatos, sem eliminar o ganho de diversidade de H1. *Refutação*: ausência de aumento do indicador, ou perda da diversidade; a ablação com e sem a guia, cruzada com TED e sorteio, separa o efeito de cada mecanismo.

4.1.0.0.1 Definições operacionais.

Válida é a molécula que passa na sanitização do RDKit com valência correta; a validade é uma restrição garantida pelo pipeline de junção, e não efeito da TED, e a taxa de novas tentativas por candidato é medida como custo. *Nova* é a molécula cujo SMILES canônico não consta da base de origem do catálogo, podendo-se estender a comparação a bancos públicos (por exemplo, PubChem). *Diversa* é medida pela diversidade interna do conjunto (média de 1 – similaridade de Tanimoto sobre ECFP4 entre pares) e pelo número de esqueletos de Bemis–Murcko distintos.

4.1.0.0.2 Escopo da avaliação espectroscópica.

O indicador de conjugação (fração dos átomos pesados no maior sistema conjugado) é uma triagem estrutural e não prevê o comprimento de onda de absorção, que também depende de efeitos doador–aceitador, planaridade e substituintes. Os resultados serão, portanto, descritos como candidatos com indicadores favoráveis à absorção UV-Vis, e não como moléculas de absorção comprovada, a menos que haja validação espectroscópica de um subconjunto (Seção 4.3).

4.2 OBJETIVO GERAL

Investigar se o uso da *Tree Edit Distance*, calculada pelo algoritmo de Zhang–Shasha, como critério de seleção de parceiros na recombinação de fragmentos aumenta a diversidade estrutural de moléculas candidatas com indicadores favoráveis à absorção UV-Vis, em comparação com a seleção aleatória.

4.3 OBJETIVOS ESPECÍFICOS

1. Construir um catálogo de fragmentos (anéis, substituintes e pontes) e um procedimento de recombinação na forma *anel–ponte–anel*;
2. Desenvolver uma representação em árvore de forma uniforme e com ordenação canônica para os anéis e seus substituintes, de modo que a distância não dependa da numeração arbitrária das posições;

3. Implementar a TED entre essas árvores pelo algoritmo de Zhang–Shasha e usá-la para selecionar o parceiro de cada anel-semente;
4. Garantir a validade química dos candidatos por junção com verificação de valência, sanitização e aromatização, com novas tentativas e deduplicação, e medir o custo dessas tentativas;
5. Comparar a seleção por TED com a seleção aleatória (H1) e com a guia de conjugação ativada ou não (H3), segundo as métricas de novidade e de diversidade definidas;
6. Verificar se a TED entre os anéis de um par se relaciona com a distância da molécula gerada (H2);
7. Calcular o indicador de conjugação dos candidatos e, em um subconjunto, validar a absorção por um método de maior nível (método a definir, por exemplo semiempírico ou TD-DFT), verificando se o indicador é adequado como triagem.

4.4 RELEVÂNCIA DA PESQUISA

A relevância desta pesquisa está em testar, com baseline e ablação, se uma distância explícita entre árvores é um critério útil para escolher o que recombinar na geração de moléculas. Ao contrário de modelos generativos treinados, a recombinação por fragmentos permite rastrear cada molécula gerada até os anéis, as pontes e os substituintes de origem, e relacionar a distância entre as estruturas de origem à da molécula resultante.

Além disso, ao separar a restrição de validade do efeito da seleção e do efeito da guia espectroscópica, o trabalho permite identificar o que cada mecanismo contribui, o que é pouco explicitado em métodos que combinam vários componentes. A contribuição está em oferecer evidência, positiva ou negativa, sobre o uso da TED na exploração computacional de um espaço químico restrito, voltada a candidatos com propriedades favoráveis à absorção UV-Vis.

5 METODOLOGIA PROPOSTA

- 5.1 VISÃO GERAL DO PIPELINE
- 5.2 GERAÇÃO DE FRAGMENTOS E COMBINAÇÃO
- 5.3 REPRESENTAÇÃO ESTRUTURAL (ÁRVORE/GRAFO)
- 5.4 AVALIAÇÃO DE DIVERSIDADE ESTRUTURAL
- 5.5 AMBIENTE E FERRAMENTAS

6 RESULTADOS PRELIMINARES

6.1 INFRAESTRUTURA DE GERAÇÃO IMPLEMENTADA

6.2 DIVERSIDADE ESTRUTURAL OBSERVADA

6.3 LIMITAÇÕES OBSERVADAS E PRÓXIMOS PASSOS

7 CRONOGRAMA

Tabela 2 – Cronograma de atividades previstas.

Atividade	T1	T2	T3	T4	T5	T6	T7	T8
-----------	----	----	----	----	----	----	----	----

Fonte: Elaborado pelo autor.

REFERÊNCIAS

- ATKINS, P.; PAULA, J. de. **Atkins' physical chemistry**. 11. ed. Oxford: Oxford University Press, 2018.
- BILLE, P. A survey on tree edit distance and related problems. **Theoretical Computer Science**, v. 337, n. 1–3, p. 217–239, 2005.
- BOHACEK, R. S.; MCMARTIN, C.; GUIDA, W. C. The art and practice of structure-based drug design: a molecular modeling perspective. **Medicinal Research Reviews**, v. 16, n. 1, p. 3–50, 1996.
- CAO, N. D.; KIPF, T. **MolGAN: an implicit generative model for small molecular graphs**. 2018. ArXiv:1805.11973.
- GENHEDEN, S.; ENGKVIST, O.; BJERRUM, E. Clustering of synthetic routes using tree edit distance. **Journal of Chemical Information and Modeling**, v. 61, n. 8, p. 3899–3907, 2021.
- GÓMEZ-BOMBARELLI, R. et al. Automatic chemical design using a data-driven continuous representation of molecules. **ACS Central Science**, v. 4, n. 2, p. 268–276, 2018.
- GUIMARAES, G. L. et al. **Objective-reinforced generative adversarial networks (ORGAN) for sequence generation models**. 2017. ArXiv:1705.10843.
- ISHITANI, R.; KATAOKA, T.; RIKIMARU, K. Molecular design method using a reversible tree representation of chemical compounds and deep reinforcement learning. **Journal of Chemical Information and Modeling**, v. 62, n. 17, p. 4032–4048, 2022.
- JENSEN, J. H. A graph-based genetic algorithm and generative model/Monte Carlo tree search for the exploration of chemical space. **Chemical Science**, v. 10, n. 12, p. 3567–3572, 2019.
- JIN, W.; BARZILAY, R.; JAAKKOLA, T. Junction tree variational autoencoder for molecular graph generation. In: **Proceedings of the 35th International Conference on Machine Learning (ICML)**. [S.l.: s.n.], 2018. (PMLR, v. 80), p. 2323–2332.
- KRENN, M. et al. Self-referencing embedded strings (SELFIES): a 100% robust molecular string representation. **Machine Learning: Science and Technology**, v. 1, n. 4, p. 045024, 2020.
- KWON, Y. et al. Evolutionary design of molecules based on deep learning and a genetic algorithm. **Scientific Reports**, v. 11, p. 17304, 2021.
- MAMEDE, R.; PEREIRA, F.; SOUSA, J. Aires-de. Machine learning prediction of UV–Vis spectra features of organic compounds related to photoreactive potential. **Scientific Reports**, v. 11, p. 23720, 2021.
- MIZRAHI, M. et al. **Cooking up creativity: enhancing LLM creativity through structured recombination**. 2025. ArXiv:2504.20643.

- OLIVECRONA, M. et al. Molecular de-novo design through deep reinforcement learning. **Journal of Cheminformatics**, v. 9, p. 48, 2017.
- OSTROVERKHOVA, O. Organic optoelectronic materials: mechanisms and applications. **Chemical Reviews**, v. 116, n. 22, p. 13279–13412, 2016.
- PAVIA, D. L. et al. **Introduction to spectroscopy**. 5. ed. Stamford: Cengage Learning, 2015.
- POLISHCHUK, P. G.; MADZHIDOV, T. I.; VARNEK, A. Estimation of the size of drug-like chemical space based on GDB-17 data. **Journal of Computer-Aided Molecular Design**, v. 27, n. 8, p. 675–679, 2013.
- ROCHA, F. S. et al. Experimental methods in chemical engineering: ultraviolet visible spectroscopy – UV-Vis. **The Canadian Journal of Chemical Engineering**, v. 96, n. 12, p. 2512–2517, 2018.
- ROJAS, F. S.; OJEDA, C. B. Recent development in derivative ultraviolet/visible absorption spectrophotometry: 2004–2008: a review. **Analytica Chimica Acta**, v. 635, n. 1, p. 22–44, 2009.
- SILVERSTEIN, R. M.; WEBSTER, F. X.; KIEMLE, D. J. **Spectrometric identification of organic compounds**. 7. ed. Hoboken: Wiley, 2005.
- SKOOG, D. A.; HOLLER, F. J.; CROUCH, S. R. **Principles of instrumental analysis**. 7. ed. Boston: Cengage Learning, 2017.
- TKATCHENKO, A. Machine learning for chemical discovery. **Nature Communications**, v. 11, p. 4125, 2020.
- WEININGER, D. SMILES, a chemical language and information system. 1. introduction to methodology and encoding rules. **Journal of Chemical Information and Computer Sciences**, v. 28, n. 1, p. 31–36, 1988.
- WORAKUL, T. et al. Generative design of singlet fission materials leveraging a fragment-oriented database. **Chemical Science**, v. 16, p. 17956–17969, 2025.
- YAMADA, M.; SUGIYAMA, M. Molecular graph generation by decomposition and reassembling. **ACS Omega**, v. 8, n. 22, p. 19575–19586, 2023.
- YOO, P. et al. Deep learning workflow for the inverse design of molecules with specific optoelectronic properties. **Scientific Reports**, v. 13, p. 20031, 2023.
- YOU, J. et al. Graph convolutional policy network for goal-directed molecular graph generation. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2018. v. 31.
- ZHANG, K.; SHASHA, D. Simple fast algorithms for the editing distance between trees and related problems. **SIAM Journal on Computing**, v. 18, n. 6, p. 1245–1262, 1989.
- ZHANG, K.; STATMAN, R.; SHASHA, D. On the editing distance between unordered labeled trees. **Information Processing Letters**, v. 42, n. 3, p. 133–139, 1992.